

筆電定價預測專案與 CRISP-DM 開發流程整合摘要報告

1. 專案執行摘要 (Executive Summary)

戰略背景與目標：在電子商務與 3C 零售的動態市場中，精準定價是維持競爭力與毛利的核心。傳統定價過於依賴採購經驗或競爭對手的隨動策略，缺乏量化的邏輯支撐。本專案致力於轉向數據驅動 (Data-driven) 的決策範式，透過分析筆記型電腦的硬體規格 (品牌、RAM、機身重量、作業系統等)，建立預測模型以量化硬體組成與終端售價間的關係，為新產品定價與市場存貨調整提供客觀依據。

核心開發範式：本專案嚴格遵循 **CRISP-DM (Cross-Industry Standard Process for Data Mining)** 標準流程。從商務理解出發，透過結構化的資料清洗與特徵工程，建立「多元線性回歸 (Multiple Linear Regression, MLR)」作為基準模型。此結構化流程確保了技術開發與商業目標的高度對齊，並為後續演算法的迭代奠定了穩健基礎。

關鍵價值主張：

- 自動化定價建議：即時估算新進機種的合理市場歐元售價，大幅縮短產品上架決策週期。
- 市場異常價格偵測：透過分析預測偏離度，識別定價過高 (Overpriced) 或潛在低估 (Undervalued) 的機種。
- 產品成本結構透視：量化各項物理規格對價格的邊際貢獻 (例如：每增加一公斤機身重量對預測成本的具體影響)。

章節銜接：下一章將詳細說明如何將 Python 實作細節對應至 CRISP-DM 框架，並揭露初步建模所產出的量化指標。

2. CRISP-DM 實作對齊分析 (CRISP-DM Implementation Mapping)

實作背景說明：嚴格遵守 CRISP-DM 框架能有效降低開發風險，並確保模型具備高可維護性。透過結構化的階段劃分，我們能清楚定義特徵處理 (如編碼、清理) 對最終預測精準度的實質貢獻。

階段與 Python 程式碼對應分析：

CRISP-DM 階段	專案 <code>train_model.py</code> 具體動作與技術細節
-------------	--

Business Understanding	商務目標定義：建立自動估價模型，將複雜硬體參數轉化為合理的歐元售價。
Data Understanding	資料探勘：使用 <code>latin-1</code> 編碼載入 <code>laptop_price.csv</code> 解決解析錯誤；初步分析 <code>Ram</code> 、 <code>Weight</code> 及 <code>Company</code> 欄位的數值分佈與類別分佈。
Data Preparation	資料清洗與特徵工程：移除 <code>Ram</code> 的 "GB" 與 <code>Weight</code> 的 "kg" 並執行型別轉換 (int/float)。針對類別變數執行 One-Hot Encoding，並使用 <code>drop_first=True</code> 剔除基準線，防止虛擬變數陷阱 (Dummy Variable Trap)，確保模型不會因完全共線性而失真。
Modeling	模型建立：將資料集以 8:2 隨機切分 (<code>random_state=42</code>)；採用多元線性回歸演算法擬合特徵與目標變數。
Evaluation	模型評估：產出 <code>evaluation_plot.png</code> 觀測殘差分佈；計算 平均絕對誤差 (MAE) 與相關係數矩陣。根據 <code>price_vs_weight.png</code> 的基準線性擬合，得出回歸公式為 $y = 221.0x + 673$ ，代表機身重量每增加 1kg，基準價格貢獻約 221 歐元。
Deployment	系統部署：打包浮點數權重 (Weights) 與推論邏輯，供後續整合至 Web API 或邊緣端裝置。

關鍵技術決策評價：使用多元線性回歸作為基準模型是極佳的戰略決策。其公式 ($y=221.0x+673$) 提供了極高的可解釋性，能讓業務決策者快速理解規格與價格的線性關係。

3. 實驗結果與殘差洞察 (Experimental Results & Residual Insights)

模型成效綜述：從 `evaluation_plot.png` 可以觀察到，模型雖能捕捉筆電價格的大致趨勢，但在高價位區間出現了顯著的「異質變異性 (Heteroscedasticity)」。隨著實際價格提升，樣本點相對於「完美預測線」的離散程度顯著增加 (呈現漏斗狀擴張)，這揭示了線性模型在處理高附加價值產品時的系統性偏差。

具體樣本誤差解構：基於 `test_predictions.csv` 的數據，我們對殘差進行深度分析：

- 極致輕薄機種 (Toshiba 案例)：

- 規格與數據：Notebook, 8GB, 1.05kg。實際價格 **1672.0** 歐元，預測僅 **1011.62** 歐元(負向殘差 -660.38)。
- 洞察：模型顯著低估了「輕量化」的技術溢價。在商務機市場中，極致輕薄(1.05kg)往往涉及昂貴的材料科學，線性模型僅將重量視為單純的線性加減項，未能反映「輕量與高效能並存」的非線性溢價。
- 中低階文書機 (Lenovo 案例):
 - 規格與數據：Notebook, 6GB, 2.4kg。實際價格 **499.0** 歐元，預測 **830.94** 歐元(正向殘差 +331.94)。
 - 洞察：模型對低端市場產生高估，顯示在預算有限的消費區間，品牌與特定組件(如螢幕面板品質)的成本縮減幅度超過了純硬體規格的線性衰減。
- 高效能電競機 (MSI 案例):
 - 規格與數據：Gaming, 16GB, 3.78kg。實際價格 **2499.0** 歐元，預測 **2006.15** 歐元(誤差 -492.85)。
 - 洞察：對於高效能電競機種，模型出現預測落後。這顯示線性模型無法捕捉到高階 CPU/GPU 組合所帶來的「效能堆疊效應」。

線性模型侷限性評估：多元線性回歸無法處理「非線性交互作用」。筆電市場中，品牌溢價(如 Razer、Apple 的 Premium 效果，見 `price_vs_opsys.png` 離群值)與核心零件之間通常是乘數效應而非加法關係。當前的線性模型在應對價格長尾分佈(Right-skewed distribution)時顯得力有未逮。

4. 網路主流與更優解法比較 (Benchmark & Advanced Solutions)

優化必要性分析：僅依賴 RAM 與重量等基礎特徵無法反映產品的真實市場定位。為了解決上述的異質變異性問題，必須引入更精細的特徵工程與能處理非線性關係的演算法。

技術升級路徑對比：

優化維度	方法描述	預期優點	潛在缺點
特徵工程優化	透過 <code>ScreenResolution</code> 計算 PPI (Pixels Per Inch) ; 利用 <code>Regex</code> 拆解 CPU 代數與 SSD 存儲。	精準捕捉高解析度螢幕與存儲技術對成本的直接貢獻。	特徵維度增加，若樣本不足可能導致過擬合。
目標變數轉換	對 <code>Price_euros</code> 進行對數轉換 (Log Transformation)。	有效解決異質變異性，將價格的長尾分佈壓縮為常態分佈，改善殘差分佈。	預測值需進行 <code>exp()</code> 反向轉換，商務解釋較不直觀。

演算法升級	引入梯度提升樹 (XGBoost / LightGBM)。	自動捕捉特徵間的複雜非線性關係(如: 品牌 * 高階 GPU 的乘數溢價)。	失去了線性回歸的直觀公式, 且推論運算量增加。
-------	-------------------------------	--	-------------------------

解決方案建議: 針對「非線性溢價」問題, 建議優先實施「目標變數對數轉換 + PPI 特徵導入」。這能修正模型在高價位區間的系統性偏差, 並保留線性模型在部署端的優勢。

5. 系統部署與工程權衡 (System Deployment & Engineering Trade-offs)

工程環境脈絡: 當模型從實驗室環境遷移至資源受限的邊緣裝置(如零售終端 MCU 或 RTOS 系統)時, 架構師必須在「預測精度」與「運算開銷」之間進行深度權衡。

模型權衡 (Trade-off) 矩陣分析:

評估維度	傳統線性模型 (MLR)	進階樹狀模型 (XGBoost/LGBM)
運算資源 (Compute)	極低: 僅需向量點積運算 ($O(1)$), 對處理器負荷微乎其微。	中/高: 涉及多層決策樹尋訪 (Tree Traversal), 功耗較大。
記憶體佔用 (Footprint)	極小: 僅需儲存少量浮點數權重, 適合 Flash 空間受限的裝置。	中: 需儲存大量樹狀節點與分裂閾值, 佔用較多存儲空間。
即時性 (Latency)	優: 推論延遲為微秒級, 適合極致即時的互動環境。	良: 取決於樹深度, 延遲隨模型複雜度線性增長。

部署決策指導: 在需要即時定價建議且硬體資源有限的場景下, 優化特徵工程後的「多元線性回歸」仍然是最佳選擇。雖然它無法完美捕捉品牌溢價的「乘數乘積」, 但其穩定性與低功耗使其在工程落地時具備更高的成本效益。

結論: 本報告透過 CRISP-DM 流程梳理了筆電定價模型的開發路徑。儘管基礎線性模型在處理高端溢價時存在侷限性, 但其揭示的量化成本結構(如 $y=221x+673$)為商務決策提供了第一手證據。未來的改進應聚焦於對數轉換與衍生特徵(PPI)的整合, 以在精度與部署效率間取得最佳平衡。